



ENGENHARIA DE COMPUTAÇÃO

Anna Julia de Souza Renger, 212047

Guilherme Januário Serafim, 248245

Mateus Pasquotto Lulia Bellotto, 248224

Rodrigo Lopes de Oliveira Cardoso, 248312

Victor Rafael Soares Otacílio, 248689

Banco de Dados, Tema do Projeto: Inteligência Artificial e Machine Learning em Bancos de Dados

Prof. Marco Montebello

Sorocaba / SP

Setembro, 2025

SUMÁRIO

1. O futuro da Inteligência Artificial e Machine Learning em Banco de Dados.....	3
1.1. Conceitos Principais.....	3
1.2. Características Principais.....	4
1.3. Análise crítica sobre as vantagens e desvantagens da tecnologia utilizada.....	5
2. Referências Bibliográficas	7
3.1. Para que é usado e como pode ser útil às empresas ou processos.....	7
3.2. Exemplo de ferramentas que o implementam.....	8
3.3. Estudo de caso real onde a tecnologia foi implementada com sucesso.....	10

1. O FUTURO DA INTELIGÊNCIA ARTIFICIAL E MACHINE LEARNING EM BANCO DE DADOS

Atualmente, a Inteligência Artificial tem se tornado cada vez mais presente no dia a dia das pessoas. O uso de IA (Inteligência Artificial) e aprendizado de máquina (Machine Learning) para gerenciar bancos de dados não é algo novo, mas mostra-se altamente eficiente em termos de performance, eficiência operacional e redução de custos. Além disso, auxilia desenvolvedores e analistas ao simplificar a interação com os dados e integrar análises avançadas em bancos de dados corporativos.

A integração de IA com bancos de dados não apenas melhora a eficiência, mas também impulsiona a geração de insights. Modelos de ML podem ser usados para prever demanda, identificar clientes com alto valor de vida útil, recomendar produtos personalizados e analisar sentimentos em grandes volumes de dados, como avaliações e feedbacks. A qualidade dos dados é fundamental para o sucesso desses modelos, e a combinação de IA com bancos de dados permite que organizações extraiam insights mais precisos e relevantes.

1.1. CONCEITOS PRINCIPAIS

A Inteligência Artificial (IA), especialmente o Machine Learning (ML), pode aprimorar bancos de dados em duas frentes: Na análise e previsão sobre os dados armazenados e na automação e otimização do próprio Sistema Gerenciador de Banco de Dados (SGBD). Ao aprender padrões de cardinalidade e correlações, os modelos auxiliam o otimizador a escolher planos de execução mais eficientes — ordem de junções (joins), métodos de acesso, uso de índices, particionamento e até caching preditivo — reduzindo latência e custos.

No campo da segurança, técnicas de detecção de anomalias permitem identificar comportamentos suspeitos, como picos de frequência de consultas, acessos em horários atípicos, padrões incompatíveis com perfis de usuários, consultas fora do expediente, tentativas de SQL Injection e outros desvios. Essas abordagens complementam (sem substituir) boas práticas como parametrização de consultas, controle de acesso, criptografia e auditoria. Setores como o financeiro se beneficiam de forma significativa, devido à sua alta sensibilidade a fraudes e acessos indevidos.

Vários bancos de dados modernos já incorporam IA e ML diretamente em suas arquiteturas. Por exemplo, o Oracle Autonomous Database utiliza IA desde 2017 para automatizar tarefas operacionais, reduzindo a necessidade de intervenção humana. O Oracle Database oferece suporte ao machine learning diretamente no banco de dados, permitindo a exploração de dados, modelagem e uso de mais de 30 algoritmos de alto desempenho via SQL, Python, R e interfaces sem código. Da mesma forma, o BigQuery da Google Cloud integra o BigQuery ML, que permite criar, treinar e implantar modelos preditivos diretamente em um data warehouse usando SQL, além de se conectar à Vertex AI para inferência em tempo real.

Apesar dos avanços, a IA não substitui completamente os profissionais de banco de dados. Acredita-se que a tecnologia servirá como um auxiliar, permitindo que DBAs e cientistas de dados se concentrem em decisões estratégicas, onde o julgamento humano, a criatividade e o livre arbítrio são essenciais. A demanda por profissionais capacitados em ciência de dados, machine learning e gerenciamento de bancos de dados está crescendo rapidamente, com

um aumento de 485% na procura por esses talentos em apenas um semestre. Instituições de ensino estão adaptando seus currículos para preparar estudantes para esse cenário em ascensão, unindo teoria e prática em IA e bancos de dados.

1.2. CARACTERÍSTICAS PRINCIPAIS

Para que os ganhos com IA e ML em bancos de dados sejam reais, é necessário:

- Definir objetivos e métricas;
- Treinar e validar modelos com dados adequados;
- Monitorar continuamente possíveis desvios (drift, falsos positivos/negativos).

Esse processo se insere dentro da disciplina de MLOps, que garante integração entre modelos de aprendizado e operações de banco de dados.

Além disso, é importante destacar que profissionais com conhecimento em IA/ML e SGBDs são fundamentais para esse tipo de aplicação. Não é preciso ter doutorado, mas também não se trata de algo que se “aprende rapidamente” sem uma engenharia cuidadosa e consistente.

1.3. BREVE ANÁLISE CRÍTICA — VANTAGENS E DESVANTAGENS

A seguir, sintetizamos benefícios e limitações da adoção de IA/ML **dentro** do SGBD (AutoML e suporte nativo, como BigQuery ML), com foco em impactos práticos no desempenho, custo e operação (GOOGLE CLOUD, 2025; MICROSOFT CORPORATION, 2025).

Vantagens

- **Menor atrito “dados → modelo” (in-database ML):** treinar e servir modelos perto dos dados evita extrações, reduz ETL e acelera o ciclo analítico (SQL-first, menos ida-e-volta entre ferramentas).
- **Acesso democratizado via SQL/AutoML:** equipes que dominam SQL prototipam e avaliam modelos (classificação, regressão, clustering, séries temporais) com baixa barreira de entrada.
- **Operação mais simples em nuvem:** serviços gerenciados (ex.: BigQuery ML) reduzem provisionamento, *scaling* e *patching* — útil para equipes pequenas e atividades acadêmicas.
- **Integração nativa com governança e segurança do SGBD:** controle de acesso, trilhas de auditoria, *masking/row-level security* e catálogos favorecem compliance (LGPD).
- **Custos proporcionais ao uso (pay-as-you-go):** em cargas intermitentes, pagar por consulta/treino pode ser mais barato que manter clusters dedicados 24×7.
- **Time-to-value em casos comuns:** para problemas “bem-comportados” (churn, propensão, anomalias), AutoML entrega qualidade “boa o suficiente” rapidamente.

Como medir se valeu a pena: tempo de ciclo (ideia→modelo→resultado), latência p95/p99 em consultas com *scoring*, qualidade do modelo (AUC/accuracy/lift) e custo por treinamento/previsão.

Desvantagens

- **Custo de implementação e infraestrutura:** Sistemas de IA exigem servidores com alta capacidade de processamento, armazenamento e licenças específicas. Para pequenas e médias empresas, isso pode representar barreiras financeiras consideráveis.
- **Complexidade operacional (MLOps):** O desenvolvimento, treinamento e monitoramento de modelos de ML requerem profissionais híbridos experientes em engenharia de dados, estatística e administração de SGBDs e infraestrutura para versionar dados/modelos, monitorar, fazer A/B e rollback.
- **Risco de erros, qualidade de dados e drift:** Modelos mal treinados podem gerar planos de execução incorretos, classificações erradas ou detecções de anomalias falsas (falsos positivos/negativos), impactando diretamente o desempenho e a segurança dos dados. Modelos também degradam com mudanças de padrão; dados ruidosos/viés geram decisões ruins — e AutoML pode ocultar detalhes importantes. Além disso, os dados mudam com o tempo e os modelos treinados podem se tornar obsoletos ou enviesados, comprometendo a precisão das previsões. Esse fenômeno exige monitoramento contínuo e retraining periódico.
- **Dependência tecnológica e vendor lock-in:** Ferramentas proprietárias, como BigQuery ML (Google) ou Oracle Autonomous Database, dificultam a migração entre plataformas, criando dependência de fornecedores e reduzindo a flexibilidade da empresa.
- **Privacidade e explicabilidade:** A IA pode tomar decisões complexas que nem sempre são facilmente explicáveis. Isso gera desafios de transparência e auditoria, especialmente em contextos regulatórios que exigem justificativa para cada decisão automatizada, conforme previsto na LGPD e no GDPR.
- **Cobertura algorítmica e de *features* limitada:** catálogos, *tuning* e interpretabilidade menores que em *stacks* dedicadas (scikit-learn/TF/PyTorch).
- **Lock-in do fornecedor/engine:** sintaxe, tipos e empacotamento variam; portar para outro SGBD/serviço pode exigir reescrita.
- **Imprevisibilidade:** cobrança por consulta/bytes e por treino pode surpreender sem *quotas* e *budgets*; inferência *on-line* adiciona custo recorrente.
- **Overhead de execução e concorrência:** *scoring* em tempo de consulta pode aumentar latência/compilação de planos e disputar recursos com OLTP/OLAP críticos.
- **Explainability/compliance:** modelos “caixa-preta” e AutoML dificultam justificar decisões sensíveis (crédito/saúde); exigem documentação e relatórios de explicabilidade.
- **Lacunas de MLOps completo:** versionamento, *feature store*, testes A/B e *rollback* podem depender de integrações extras.

Mitigações rápidas (boas práticas)

- **SLOs e *fallback*:** metas de latência (p95/p99) e plano determinístico caso o *scoring* piore a experiência.
- **Guardrails de custo:** *quotas*, *budgets* e *alerts*; preferir *batch scoring* para relatórios e usar *on-line* só onde fizer diferença.
- **Governança e qualidade de dados:** validações, deduplicação, linhagem e monitoramento de *drift*; “*human-in-the-loop*” para correções automáticas.

- **Portabilidade:** exportar modelos em formatos abertos (quando possível), manter *features* em SQL portátil e separar lógica de negócio da plataforma.
- **Auditoria e explicabilidade:** registrar versões, hiperparâmetros e métricas; gerar explicações (SHAP/*feature importance*) em decisões sensíveis.

Fecho crítico. Em cenários simples (dados estáveis, consultas previsíveis), bons **índices e SQL otimizado** podem ser suficientes; o **in-database ML/AutoML** compensa quando há **volume/variedade** e demanda por **predição próxima aos dados**.

2. Referências bibliográficas

- CHOLLET, François. *Deep Learning com Python*. 2. ed. Rio de Janeiro: Alta Books, 2021.
- HAN, Jiawei; KAMBER, Micheline; PEI, Jian. *Data Mining: Concepts and Techniques*. 4. ed. Burlington: Morgan Kaufmann, 2023.
- KUHN, Max; JOHNSON, Kjell. *Applied Predictive Modeling*. 2. ed. New York: Springer, 2024.
- RUSSELL, Stuart; NORVIG, Peter. *Inteligência Artificial*. 3. ed. Rio de Janeiro: Elsevier, 2013.

2.1. Artigos e relatórios

- GOOGLE CLOUD. *BigQuery ML: Machine Learning in SQL*. Mountain View: Google LLC, 2025. Disponível em: <https://cloud.google.com/bigquery-ml>. Acesso em: 6 nov. 2025.
- ISLAM, Siful. *Future Trends in SQL Databases and Big Data Analytics: Impact of Machine Learning and Artificial Intelligence*. *International Journal of Science and Engineering*, v. 1, n. 4, p. 47-62, 2024.
- LIN, Yuanguo; CHEN, Hong; XIA, Wei; et al. *A Comprehensive Survey on Deep Learning Techniques in Educational Data Mining*. *Data Science and Engineering*, 2025. DOI: 10.1007/s41019-025-00303-z.
- MICROSOFT. *AI Integration in SQL Databases: 2024 Report*. Redmond: Microsoft Press, 2024. Disponível em: <https://learn.microsoft.com/en-us/sql/ai>. Acesso em: 6 nov. 2025.
- PARASHAR, Kushagra; DEV, Ajay; KUMAR, Aditya; KHATRI, Darpan. *Enhancing Productivity in Database Management Through AI: A Three-Phase Approach for*

Database. arXiv preprint 2504.09288, 2025. Disponível em: <https://arxiv.org/abs/2504.09288>^[OBJ]. Acesso em: 6 nov. 2025.

- SINGH, Aditi; SHETTY, Akash; EHTESHAM, Abul; KHOEI, Talaei. *A Survey of Large Language Model-Based Generative AI for Text-to-SQL: Benchmarks, Applications, Use Cases, and Challenges*. arXiv preprint 2412.05208, 2024. Disponível em: <https://arxiv.org/abs/2412.05208>^[OBJ]. Acesso em: 6 nov. 2025.

3.1 Para que é usado e como pode ser útil às empresas ou processos.

A aplicação da Inteligência Artificial (IA) e do Machine Learning (ML) em bancos de dados tem como principal objetivo transformar o modo como as organizações armazenam, processam e utilizam informações.

Essas tecnologias são utilizadas para automatizar tarefas complexas, identificar padrões ocultos nos dados e melhorar a tomada de decisões empresariais por meio de análises preditivas e prescritivas.

No contexto corporativo, o ML pode aprender automaticamente com os próprios dados da empresa e, a partir disso, ajustar o desempenho do Sistema Gerenciador de Banco de Dados (SGBD).

Isso ocorre, por exemplo, quando o sistema identifica consultas lentas e reorganiza índices ou particionamentos de forma autônoma, otimizando a performance sem necessidade de intervenção manual.

Além disso, a IA é usada para prever demandas, detectar anomalias de segurança, corrigir inconsistências e até classificar informações sensíveis para fins de conformidade com a LGPD (Lei Geral de Proteção de Dados).

Essas aplicações reduzem falhas humanas, aumentam a eficiência operacional e permitem respostas em tempo real a eventos críticos, como fraudes ou sobrecargas de sistema.

Do ponto de vista estratégico, o uso de IA e ML em bancos de dados torna as empresas mais competitivas e sustentáveis, já que a automatização de rotinas libera os profissionais para focarem em inovação, e não apenas em manutenção.

Em suma, essas tecnologias permitem que o banco de dados evolua de um simples repositório de informações para um sistema inteligente, adaptativo e decisório, essencial na era do Big Data e da transformação digital.

3.2. Exemplo de ferramentas que o implementam (nome, empresa fabricante, gratuita ou não)

O futuro da Inteligência Artificial (IA) e Machine Learning (ML) em bancos de dados envolve a utilização de diversas ferramentas, tanto de grandes provedores de nuvem quanto de código aberto. Abaixo estão exemplos de ferramentas que implementam essas tecnologias, com seus respectivos fabricantes e modelos de licenciamento:

Nome da Ferramenta	Empresa Fabricante	Gratuita ou Não	Descrição/Uso em Bancos de Dados
Vertex AI	Google Cloud	Não (paga, com camada gratuita inicial)	Plataforma unificada para criar, implantar e gerenciar modelos de ML e IA generativa, que pode se integrar a soluções de banco de dados na nuvem.
IBM Watson Studio	IBM	Não (paga, com teste gratuito)	Parte da plataforma IBM Watson, oferece um ambiente para análise de dados e construção de modelos de ML, conectando-se a várias fontes de dados.
Azure Machine Learning	Microsoft (Azure)	Não (paga, com camada gratuita inicial)	Uma plataforma para o ciclo de vida completo do ML, desde o processamento de dados em bancos de dados Azure até a implantação de modelos.
Amazon SageMaker	Amazon Web Services (AWS)	Não (paga, com camada gratuita inicial)	Serviço de ML totalmente gerenciado que ajuda os desenvolvedores e cientistas de dados a criar, treinar e implantar modelos de ML em escala, utilizando dados de bancos AWS (como S3, Aurora).

H2O.ai	H2O.ai	Sim (versão Open Source) e Não (versão Enterprise)	Oferece a plataforma de ML de código aberto H2O e a plataforma paga AI Hybrid Cloud (H2O AI Cloud), utilizadas para análise de dados e modelagem preditiva em larga escala.
Scikit-learn	Comunidade (código aberto)	Sim (Gratuita/Open Source)	Biblioteca popular de ML para a linguagem Python, utilizada para mineração de dados e análise, que pode ser integrada a sistemas que gerenciam bancos de dados

TensorFlow	Google(mantido pela comunidade)	Sim (Gratuita/Open Source)	Um framework de código aberto para ML e deep learning, flexível para experimentação e implantação em diversos cenários de dados.
PyTorch	Meta (mantido pela comunidade)	Sim (Gratuita/Open Source)	Outro framework de deep learning de código aberto, conhecido por sua flexibilidade e facilidade de uso em pesquisa e desenvolvimento

3.3. Caso real onde a tecnologia foi implementada com sucesso

A aplicação mais consolidada de IA e ML em bancos de dados é a detecção de fraudes em tempo real. Instituições financeiras analisam padrões de transações para identificar anomalias e prevenir perdas como por exemplo o Danske Bank (países nórdicos) aumentou a detecção de fraudes em 50% e reduziu falsos positivos em 60% após implementar modelos de machine learning. Isso permitiu realocar equipes para tarefas estratégicas e reduzir custos com investigações também tem os bancos brasileiros, diante de um aumento de 9,5% nas fraudes em 2017, têm investido pesadamente em IA para diferenciar transações legítimas de fraudulentas em segundos, minimizando bloqueios indevidos e melhorando a experiência do cliente.

Empresas como Spotify e LinkedIn usam ML integrado a bancos de dados para oferecer experiências personalizadas como por exemplo o Spotify analisa milhões de interações musicais em seu banco de dados para gerar recomendações personalizadas via modelos de aprendizado de máquina e o LinkedIn utiliza ML para sugerir conexões, vagas de emprego e conteúdos relevantes no feed, com base no comportamento e perfil dos usuários.

Para automação de processos com Bancos de Dados Autônomos o Oracle Autonomous Database é um exemplo de implementação bem-sucedida de IA em gestão de dados pois desde 2017, o sistema usa IA para automatizar tarefas como correção de falhas, otimização de desempenho e segurança, reduzindo a intervenção humana em até 80% que por sua vez permite a execução de modelos de ML diretamente no banco de dados via SQL, Python ou R, com suporte a formatos como ONNX e acesso a GPUs para inferência em tempo real.